

Wafer Fabrication Data Preprocessing & Machine Learning for Semiconductor Process Control

†Sung-Soo Kim • Young-Hun Cha • Seok-Min Jung • Seong-Il Na

*Department of Industrial Engineering, Kangwon National University

반도체 공정 관리를 위한 웨이퍼 가공 데이터 전처리 및 기계 학습

†김성수* • 차영훈** • 정석민** • 나승일**

강원대학교 산업공학과

초록 (Abstract)

본 연구의 목적은 효율적인 반도체 공정관리를 위한 데이터 전처리 방법과 데이터의 레이블 정보가 존재 또는 존재하지 않는 다양한 상황 하에서 해 예측 또는 탐색 및 평가를 할 수 있는 웨이퍼 가공 전처리 및 기계 학습 (Wafer Fabrication Data Preprocessing & Machine Learning, WFDPML) 방법을 제안하는 것이다.

본 연구에서 제안하는 WFDPML은 군집 수와 레이블 정보의 유무에 따라 지도 학습 (Supervised learning) 또는 비지도 학습 방식(Unsupervised learning) 과정을 이원화하여 제공할 수 있다. UCI SECOM 웨이퍼 가공 데이터와 같이 양품 또는 불량품 레이블이 존재하는 경우, 군집 간 불균형을 판단하여 Over-sampling 또는 Under-sampling을 적용하고 지도 학습 방법을 적용하여 분류 해를 예측하고 F1 score로 예측 해를 평가할 수 있다. 만약, SECOM 데이터에 레이블이 존재하지 않는다고 가정할 경우, 비지도 학습 방법을 적용하여 군집 수를 결정하고 데이터의 유사성 평가 기준 (Intra-cluster distance, Silhouette 등)으로 군집 해를 평가하고 탐색할 수 있다. 이와 같은 웨이퍼 가공 데이터 분류 (Classification) 또는 군집(Clustering) 문제를 해결할 수 있는 WFDPML 방법의 성능을 실험 및 분석을 통하여 검증하였다.

Keywords : Wafer Fabrication, Semiconductor, Machine Learning, Clustering, Classification

† Corresponding author: kimss@kangwon.ac.kr

1. 연구의 배경 및 목적

수율 (yield, 收率)은 투입 수에 대한 완성된 양품(良品)의 비율을 나타내는데, 특히 반도체의 생산성, 수익성 및 업체의 성과 면에서 매우 중요하다. (네이버 지식백과, 2022). 반도체 공정 중간중간에 결함과 불량인지를 검사하고, 원하는 모양대로 잘 만들어졌는지 계측한다. 공정 중 발생하는 결함은 제품 개발과 생산에 영향을 미치는데, 공정 관리는 결함을 적절히 검출하고 제어해주는 역할을 한다. (서희원, 전자신문, 2021년6월1일). 공정 관리 시 각 센서에서 수집되는 특성 데이터를 분석하고 조절해 공정을 원하는 상태로 유지할 수 있다. 이와 같은 반도체 공정 관리를 통하여 새로운 결함을 식별해 제조 수율과 수익성 향상이 가능하다.

최근 예방 유지보수 (Preventive maintenance) 또는 웨이퍼 불량을 사전에 방지하기 위해서는 공정 상의 문제와 원인을 사전에 파악하고 진단을 한 후 대책을 찾아 문제를 해결해야 한다. 웨이퍼 불량은 보통 생산 기계의 고장이나 이상에 이유가 있을 수 있다. 따라서 반도체 생산 장비의 센서에서 수집되는 데이터를 분석하여 실시간으로 웨이퍼의 양품과 불량품을 분류하고 문제점을 찾고 해결책을 찾아 사전에 예방할 수 있다.

반도체 관련 데이터는 기업의 보안 문제 때문에 한국뿐만 아니라 세계적으로도 분석할 수 있는 데이터가 매우 제한되어 있다. 따라서, 기존 연구에서는 2008년도에 Machine Learning Repository에 등록된 반도체 생산 분야 관련 UCI SECOM 데이터 (<https://archive.ics.uci.edu/ml/datasets/SECOM>)를 분석하여 반도체 공정 관리를 위한 웨이퍼 가공 데이터 전처리 및 분석을 시도하였다. SECOM 데이터는 웨이퍼 (Wafer) 최종 결과물 1567 데이터의 각각에 대하여 590개 특성 데이터로 양품 (pass, -1) 또는 불량품 (fail, 1)을 분류한다. 이 데이터는 590개 특성이라고 되어 있지만 각 특성이 무엇인지는 보안 문제로 설명하고 있지 않다. Kang & et al. (2022)은 SECOM 데이터 기반 모델을 사용하여 생산라인을 위한 상품 결함 탐지를 시도하였는데, ANOVA 특성 선택 방법, Min-Max 스케일링 정규화 방법, 결측치 (missing value) 보완을 위해 평균 입력 방법을 사용하였다. 지도 학습 분류 방법으로는 Support vector classifier (SVC), Multilayer

Perceptron (MLP), Random Forest (RF), Gradient boosted trees (GDBT)와 RUSBoosted Tree 방법을 적용하였다. Cho & et al. (2022)는 제조 프로세스에서 품질 분류 성능을 개선하기 위해 결측치 보완 방법 (Linear interpolation, Poly interpolation, KNN, MICE, Miss Forest)과 군집 간 데이터 불균형 해결 방법 (SMOTE, SMOTE-Tomek, SMOTE-ENN, ADASYN, GAN)의 데이터 전처리 조합 방법을 제안하였다. Jang & Kim (2022)은 심한 불균형과 고차원 데이터를 분석하여 이상을 탐색하기 위해 SECOM 데이터를 활용하였다. Huang (2022)도 제조 공정 상에 이상 유무를 판단하기 위해 SECOM 데이터를 활용하였다.

이와 같이 기존 반도체 데이터 분석 연구에서 사용한 SECOM 데이터는 양품, 불량품 레이블이 존재하고 사전에 레이블화되어 있는 데이터로부터 학습을 하는 것이므로 군집 수 $k=2$ 로 사전 정보가 있는 분류 문제이다. 양품 또는 불량품 군집 간의 데이터 불균형이 존재하는지 판단 가능하고 군집 간의 균형을 맞추기 위해 Over 또는 Under-sampling을 시도하고 실제 및 예측 결과에 따른 F1 score 평가 함수를 적용하였다 (Kang & et al. , Cho & et al. 2022). 만약, SECOM 데이터의 사전 정보가 없어 레이블화되어 있지 않다면, 데이터의 유사성으로 분석해야 하기 때문에 적절한 군집 수 k 를 결정해야 하고 해 평가 기준 (valid index)을 적용하여 비지도 학습 방법으로 군집화 해야 한다.

Dogan & Birant (2021)는 제조 생산 분야 (스케줄링, 품질 예측과 개선 등)에 지도 학습 또는 비지도 학습 상황에서 기계 학습이 어떻게 적용되었는지 분류하고 분석하였다. 또한, Dong (2019)은 파워 시스템의 실패 예측을 위해 실루엣(Silhouette) 평가 기준으로 클러스터 수를 결정하고 비지도 학습 방법인 K-means를 적용하고 추가적으로 지도 학습 방법 중 이진 분류에 널리 쓰이는 Logistic Regression을 적용하였다. 이와 같이 기존 레이블 정보를 알 경우 또는 알 수 없을 경우 등 다양한 종류의 데이터 분석 시 데이터 전처리 방법과 효율적인 기계 학습을 통한 해 예측 또는 탐색과 해 평가를 어떻게 할 것인지에 대한 연구가 필요하다.

따라서, 본 연구의 목적은 복잡한 반도체 제조 라인에서 수집되는 데이터를 분석하기

위한 데이터 전처리 방법과 정보의 존재 유무에 따라 지도 학습을 통한 해 예측 또는 비지도 학습을 통한 해 탐색 및 평가 방법을 제안하고자 한다. 즉, 반도체 웨이퍼 가공 수율을 향상시킬 수 있는 공정 관리를 위해 데이터 분석 시 적용 가능한 데이터 전처리 방법과 데이터의 군집 수와 레이블 정보가 존재 또는 존재하지 않을 경우 적절한 해 예측 또는 탐색 및 평가를 할 수 있는 웨이퍼 가공 전처리 및 기계학습 WFDPLM을 제안하는 것이다.


2. 데이터 분류 또는 군집 문제와 해 평가

웨이퍼 가공 데이터 분류 또는 군집 문제의 해 평가에 대하여 다음과 같이 설명한다. 2.1절에서는 기존 데이터의 레이블 정보 결과를 알 경우, 지도 학습 방법으로 예측한 군집해가 실제 레이블 결과 군집해와 얼마나 유사한지 F1 score로 평가할 수 있다. 2.2~2.3절에서는 기존 데이터의 레이블 정보 결과를 알지 못할 경우 비지도 학습 방법 적용 시 데이터의 유사성을 평가하는 기준을 설명한다. 2.2절은 군집 내 평균과 다른 데이터 간의 클러스터 내 거리 (Intra-cluster distance)를 최소화하는 것이다. 2.3절에서는 기존 데이터를 중심으로 한 군집 내와 군집 간 거리를 고려한 실루엣(Silhouette) 평가값 (-1~1)을 최대화하는 것이다.

2.1 실제와 예측 군집 해 F1 Score 평가

Hossin & Sulaiman (2015)에 따르면 F1 score 평가 방식은 기존 양품, 불량품에 대한 군집 결과 정보가 존재하고 군집 간에 데이터 수의 불균형이 존재 할 경우 이진분류모델의 성능 평가 시 가장 적합한 평가 방식으로 알려져 있다. Figure 1 이 특성 a_1 과 a_2 로 구성된 9 개의 웨이퍼 데이터 ($x_1 \sim x_9$) (5,5), (4,6), (4,7), (4,5), (5,7), (9,2), (9,3), (10,1), (10,2), (10,3)이다. 웨이퍼 가공 데이터 $x_1 \sim x_5$ 는 양품(네모 형태)이고 나머지 $x_6 \sim x_9$ 는 불량품(세모 형태)이라고 해를 나타낸 것으로 가정한다. Figure 2 는 지도 학습으로 예측한 해 좌표와 해 표현으로, 특성 a_1 과 a_2 로 분석한 예측 해 (웨이퍼 가공 데이터 x_1, x_2, x_7, x_8, x_9 는 양품으로 예측하고 나머지 $x_3 \sim x_6$ 은 불량품으로 예측한 결과)라고 가정한다. Figure 1 의 실제 결과와 Figure 2 의 예측 해 결과를 사용하여 F1 Score

계산 과정을 Table 1 오차 행렬 (Confusion matrix)을 사용하여 다음과 같이 설명할 수 있다.




(a) 9 개의 데이터 좌표

	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
군집1	0	0	0	0	0	1	1	1	1
군집2	1	1	1	1	1	0	0	0	0

(b) 9 개의 데이터 해 표현

Figure 1. 실제 해 군집 좌표와 해 표현



(a) 예측 군집 해 9 개의 데이터 좌표

	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
군집1	0	0	1	1	1	1	0	0	0
군집2	1	1	0	0	0	0	1	1	1

(b) 예측 군집 해 9 개의 데이터 해 표현

Figure 2. 예측 해 군집 좌표와 해 표현

Table 1. 오차 행렬 (Confusion matrix)

		실제 품질 (actual)		
		양품 (positive)	불량품 (negative)	
예측 품질 (predict)	양품으로 예측 (positive)	TP = 2	FP = 3	5
	불량품으로 예측 (negative)	FN = 3	TN = 1	4
		5, 실제 양품	4, 실제 불량품	

TP (True Positive)는 양품을 양품으로 예측한 경우인데, 실제 양품 $x_1 \sim x_5$ 중 $x_1 \sim x_2$ 만을 양품으로 예측하여 $TP = 2$ 가 된다. FP (False Positive)는 불량품을 양품으로 예측한 경우인데, 실제 불량품 $x_6 \sim x_9$ 중 $x_7 \sim x_9$ 을 양품으로 예측하여 $FP = 3$ 이 된다. 정밀도 (precision)는 양품(positive)으로 예측한 경우($TP + FP$) 중 실제로 양품(positive) (TP)인 비율을 나타내고 식 (1)로 나타내고 0.4 가 된다. FN (False Negative)은 양품을 불량품으로 예측한 경우인데, 실제 양품 $x_1 \sim x_5$ 중 $x_3 \sim x_5$ 를 불량품으로 예측하여 $FN = 3$ 이 된다. 재현율(recall)은 실제 양품(positive)인 것 중 올바르게 양품(positive) (TP)을 맞춘 비율을 식 (2)으로 나타내고 0.4 가 된다. F1 score 는 정밀도와 재현율의 조화 평균을 식(3)으로 나타내고 0.4 가 된다.

$$\text{정밀도(Precision)} = \frac{TP}{TP+FP} \quad (1)$$

$$\text{재현율(Recall)} = \frac{TP}{TP+FN} \quad (2)$$

$$\text{F1 score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3)$$

$$\text{정밀도(Precision)} = \frac{TP}{TP+FP} = \frac{2}{2+3} = 0.4$$

$$\text{재현율(Recall)} = \frac{TP}{TP+FN} = \frac{2}{2+3} = 0.4$$

$$\text{F1 score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{0.4 \times 0.4}{0.4+0.4} = 0.4$$

2.2 군집 내 Intra-cluster distance 해 평가

Krishna (1999)와 김성수 (2017)는 n 개의 데이터를 K 개의 그룹으로 군집하는 문제를 다음과 같이 수리적으로 표현한다. 데이터 집합 $D = \{d_1, d_2, \dots, d_n\}$ 는 데이터 i (d_i)로 구성된다 ($i = 1, 2, \dots, n$). 각각의 d_i 는 p 차원(특성)으로 구성되는데 $d_{ij} = [d_{i1}, \dots, d_{ip}]$ 는 데이터 i 의 특성 데이터 j 의 값을 표현한다. 또한, k ($k = 1, 2, \dots, K$)개의 클러스터는 서로 겹치지 않는 클러스터 서브 집합 $C = \{C_1, C_2, \dots, C_K\}$ 로 구성된다. 각 클러스터 집합은 적어도 한 개의 데이터가 존재한다. 각 클러스터 내에서 평균

과 소속된 데이터 사이의 유클리드 거리의 총합을 나타내는 식(4)을 최소화하는 것이고 제한식 (5)~(9)로 나타낼 수 있다.

$$\text{Minimize } \sum_{k=1}^K S(k) \quad (4)$$

$$\text{s.t } w_{ik} = \begin{cases} 1 & \text{데이터 } i \text{가 클러스터 } k \text{에 포함된 경우} \\ 0 & \text{그렇지 않을 경우} \end{cases} \quad (5)$$

$$\sum_{k=1}^K w_{ik} = 1, i = 1, 2, \dots, n \quad w_{ik} \in \{0, 1\} \quad (6)$$

$$\sum_{i=1}^n w_{ik} \geq 1, k = 1, 2, \dots, K \quad (7)$$

$$C_{kj} = \frac{\sum_{i=1}^n w_{ik} d_{ij}}{\sum_{i=1}^n w_{ik}} \quad (8)$$

$$S(k) = \sum_{i=1}^n w_{ik} \sqrt{\sum_{j=1}^p (d_{ij} - c_{kj})^2} \quad (9)$$

만약 데이터 i (d_i)가 클러스터 k 에 포함되었을 경우 w_{ik} 를 1로 표시하고 그렇지 않을 경우 0으로 표시하여 식(5)와 같이 정의할 수 있다. 데이터 군집 해 표현 매트릭스를 $W = \{w_{ik}\}$ 로 나타낼 수 있고 d_i 가 하나의 클러스터 k 에 포함되는 여부에 따라 식(6)과 같이 표현할 수 있다. 식(7)은 클러스터 k 에 적어도 하나 이상의 데이터 i (d_i)가 포함되어 있는 것을 표현하였다. 식(8)의 C_{kj} 는 $C_k = (C_{k1}, C_{k2}, \dots, C_{kp})$ 의 클러스터 k 에서 특성 데이터 j 의 평균값을 나타낸다. 식(9)는 클러스터 k 의 유클리드 거리의 합을 나타낸다.

예를 들어, 다음과 같이 군집 수 $k=2$ 이라 가정하고 웨이퍼 가공 품질을 양품 또는 불량품으로 분류할 수 있는 특성 $p=2$ 개 (a_1, a_2)로 이루어진 $n=9$ 개의 웨이퍼 가공 데이터 $d_1, d_2, \dots, d_9 = (5, 5), (4, 6), (4, 7), (4, 5), (5, 7), (9, 2), (9, 3), (10, 1), (10, 2), (10, 3)$ 는 Figure 1 (a) 좌표와 (b) 2 차원의 해 표현으로 양품 또는 불량품 ($k=2$ 개)으로 군집화 할 수 있다. 즉, 웨이퍼 가공 데이터 1~5 ($d_1 \sim d_5$)를 군집 2 (양품)에 포함되어 $w_{i2} = 1$ 로, 데이터 6~9 ($d_6 \sim d_9$)를 군집 1 (불량품)에 포함되어 $w_{i1} = 1$ 로 실제 해를 표현한다. 식 (4)의 해 평가 값 (각 클러스터 내에서 군집 1 과 군집 2 의 평균 $C_1(C_{11} = 9.5, C_{12} = 2), C_2(C_{21} = 4.4, C_{22} = 6)$ 과 소속된 데이터 사이의 유클리드 거리 $S(1) = 3.236$ 과 $S(2) = 4.886$ 의 총합, $\sum_{k=1}^2 S(k) = 8.122$)은 식(5)~(9)를 고려하여 계산할 수 있다.

2.3 군집 내와 군집 간 실루엣 해 평가

n 개의 데이터 $i(x_i) \{i = 1, 2, \dots, n\}$ 를 k 개의 그룹 $\{k = 1, 2, \dots, K\}$ 으로 실루엣 평가기준 식 (10)~(12)를 사용하여 군집화 할 수 있다.

예를 들어, 군집 수 $k = 3$ 이고 군집 A, B 와 C 존재한다고 하자. 군집 A 에 포함되어 있는 데이터 x_i 와 군집 A 에 속한 다른 데이터들과의 평균 거리를 $a(x_i)$ 라 할 때, 이 값이 작을수록 군집 내의 데이터들이 조밀하게 모여 있다는 것을 의미한다. 군집 A 에 속한 데이터 i 에서 군집 B 와 군집 C 에 속한 각 데이터들과의 평균거리를 각각 $d(x_i, B)$ 와 $d(x_i, C)$ 라 할 때, $b(x_i)$ 는 데이터 i 에서 다른 클러스터 B 와 C 에 포함된 데이터간의 평균 거리 중 가장 작은 값을 의미한다. 만약, $d(x_i, C)$ 가 $d(x_i, B)$ 보다 작다면 $b(x_i) = d(x_i, C)$ 가 된다. $b(x_i)$ 는 식(10)과 같이 나타낼 수 있는데, 이 값이 클수록 클러스터 간의 구별이 뚜렷하다고 판단할 수 있다. 모든 데이터 x_i 에 대하여 식(11)과 같이 $S(x_i)$ 를 구하고 합한 값 $\sum_{i=1}^n S(x_i)$ 을 데이터 수 n 으로 나누면 평균 실루엣 값을 식(12)로 $SIL(S(x_i))$ 을 구할 수 있고 실루엣 값을 최대화하여 1에 가까운 군집해를 탐색할 수 있다 (김성수 외 1인 특허 출원 등록 10-2142767).

$$b(x_i) = \min\{d(x_i, B), d(x_i, C)\} \quad (10)$$

$$S(x_i) = \{b(x_i) - a(x_i)\} / \max\{a(x_i), b(x_i)\} \quad (11)$$

$$SIL(S(x_i)) = (1/n) \sum_{i=1}^n S(x_i) \quad (12)$$

웨이퍼 가공 데이터 군집 해를 평가할 때 실루엣 평가기준 식(10)~(12)를 사용하여 데이터 x_i 에 대한 실루엣 $S(x_i)$ 와 모든 데이터가 포함된 군집 해에 대한 실루엣 값 $SIL(S(x_i))$ 를 계산한다.

Figure 1 (a) 좌표와 (b) 2차원의 해 표현으로 양품 또는 불량품 ($k=2$ 개)으로 실루엣 평가 기준으로 군집화 할 수 있다. 양품 군집에 포함되어 있는 데이터 x_i (x_1)와 양품 군집에 속한 다른 데이터들($x_2 \sim x_5$)과의 평균 거리는 $a(x_i)$ [즉, $a(x_1) = 1.662$]이다. 양품(군집 A)과 불량품(군집 B)으로 군집 2개로 이루어지기 때문에 $b(x_1)$ 는 $d(1, B) = 5.426$ 이고 식(10)은 $b(x_1) = d(x_1, B) = 5.426$ 이다. 따라서, 식(11)로 $S(x_1) = \frac{b(x_1) - a(x_1)}{\max\{a(x_1), b(x_1)\}} = \frac{5.426 - 1.662}{5.426} = 0.693$ 를 계산할 수 있다. 식(12)를 적용하여

실루엣 값은 0.775이다. 위 예제의 실루엣 값이 1에 가까운 0.775이므로 클러스터 내의 데이터들은 조밀하게 모여 있고 각 클러스터 간의 데이터들은 뚜렷하게 구별된다는 의미이다 (Rousseeuw, 1987).

3. 반도체 웨이퍼 가공 데이터 분석 방법

반도체 웨이퍼 가공 데이터 분석을 하기 위한 WFDPMML 단계별 설명은 다음과 같고 Figure 3은 플로우 차트를 나타낸다.

WFDPMML 데이터 전처리 과정은 다음과 같다. 단계 1에서는 웨이퍼 가공 데이터를 준비한다. 단계 2에서는 데이터 읽고 파라미터 M 과 Q 를 결정한다. M 은 결측치가 전체 데이터의 $m\%$ 이상인 특성 수를, Q 는 특성과 양품 불량품 결정과의 상관계수가 가장 높은 q 개 특성 적용을 나타낸다. 단계 3은 표준편차가 0인 특성 데이터는 각 특성을 나타내지 못하기 때문에 해당 특성 데이터를 제거한다. 단계 4는 결측치가 존재하는지 판단하여 존재할 경우, 해당 결측치가 전체 데이터의 $m\%$ 이상인 특성의 수 M 만큼 제거한다. 만약, 해당 결측치가 전체 데이터의 $m\%$ 이하인 특성은 결측치가 없는 데이터의 평균으로 대체한다. 단계 5에서는 특성 간의 단위, 규모가 불일치할 경우 스케일링 (Scaling)을 시행한다.

WFDPMML 지도 학습 과정인 경우는 다음과 같다. 단계 6에서는 기존 데이터의 레이블에 대한 실제 정보가 존재하기 때문에 필요할 경우, 상관 계수가 가장 높은 q 개의 특성 선택이 가능하다. 군집 간에 불균형이 있다고 판단 될 경우 Over 또는 Under-Sampling 을 시행한다. Logistic Regression, Support Vector Machine 등 지도 학습 방법을 적용하여 분류해 결과를 예측하고 각각의 최선 해 결과에 대한 F1 score 값을 제시한다.

WFDPMML 비지도 학습 과정인 경우는 다음과 같다. 단계 7에서는 기존 데이터의 레이블에 대한 실제 정보가 존재하지 않을 경우, 군집 수의 결정이 필요하고, 비지도 학습 방법인 조화로운 메타휴리스틱 알고리즘 (Harmonious Meta-Heuristic Algorithm, HMHA, 김성수 외 2인 특허 출원 10-2022-0088295)을 적용하여 최선 해를 탐색한다.




Figure 3 웨이퍼 가공 전처리 및 기계학습, WFDPMML)

다양성과 수렴적 탐색 조정이 가능한 HMHA는 초기해 군 K-means 생성 비율, 해군의 수, 돌연변이율, 엘리티즘 (Elitism) 조정을 통하여 초기에는 다양한 탐색으로 다수의 지역 해들을 탐색하고 탐색이 진행될수록 수렴적 탐색으로 최선해 탐색을 효율적으로 탐색한다. HMHA의 해 평가 기준은 Intra-cluster distance만 사용하였으나 WFDPMML은 Silhouette 평가 기준도 적용할 수 있다. HMHA의 초기해의 성능을 개선하기 위해 데이터간의 상대적인 거리 비율과 클러스터의 중심 데이터간의 거리를 고려한

해 생성 방법 (김성수 외 1인 특허 출원 등록 10-2142767)을 추가로 적용하였다.

4. 실험 및 분석

Espadinha-C. & et al. (2021)에 따르면 반도체 생산공정은 매우 복잡하고 긴 리드타임(lead time)의 특징이 있다. Figure 4와 같이 반도체 생산 공정을 단순화 하여 나타낼 수 있는데, 오른쪽 웨이퍼 가공 과정에서 생성되는 SECOM 데이터를 본 논문에서 제안하는 WFDPMML로 실험 분석하고 성능을 검증한다. 4.1절은 데이터 전처리 과정이고 4.2절은 군집 수와 레이블 정보가 존재할 경우 지도 학습 방법 적용 과정이다. 4.3절은 정보가 존재하지 않을 경우 비지도 학습 방법 적용 과정을 서술하였다. 실험은 윈도우10 프로세서: Intel(R) Core™ i5-4590 CPU @ 3.30GHz 3.30 GHz RAM: 8GB, 64비트 운영 체제, x64 기반 프로세서 운영체제, Python으로 실행한다.





Figure 4. 웨이퍼 가공과 반도체 생산 공정 Espadinha-C. & et al. (2021)


4.1 데이터 전처리

SECOM 데이터는 1567개이고 각 데이터당 590개의 특성들을 센서들로부터 수집되어 구성된다. 각 데이터는 웨이퍼 가공 생산 라인에서 1463개 양품과 104개 불량품으로 분류되어 레이블이 표시된다. 590개 특성 중에서 116개 (19.6%)의 특성이 1567개의 모든 데이터 특성이 일정한 상수(표준편차가 0)로 표시되어 제거하였고 나머지 474개의 특성이 데이터 분석 시 사용할 수 있다. 590개의 특성 중 결측치가 전체 데이터의 80%이상, 50%

이상, 5%이상의 특성 수는 8개, 32개, 52개인 것으로 조사 되었고 분석자의 판단에 따라 몇 %이상 결측치가 있을 경우 분석할 때 특성을 삭제 할 것인지 결정할 수 있다. 예를 들어, 본 연구에서는 590개의 특성 중 전체 데이터의 5%이상의 결측치가 존재하는 52개 (특성 번호 sensor 72, 73....578~581이 포함) 특성 수를 제외하였다. 결측치가 전체 데이터의 $m=5\%$ 이하인 특성 번호 sensor 0, 1, 2, 3 등 결측치를 평균 3014.45, 2495.85, 2200.54, 1396.37 등으로 채워 넣었다. 1567개 데이터의 422개 특성 (590개 특성 중 상수로 표시 된 116개와 결측치가 전체 5%이상인 52개 제외) 들을 스케일링 할 수 있다. 예를 들어, 레이블 정보가 존재할 경우, 상관 계수 상위 $Q=20$ 개 특성 번호는 Sensor 59, 103, 510, 348, 431, 434, 430, 435, 21, 28, 436, 129, 210, 298, 163, 124, 295, 160, 316, 164 이고, 상관 계수 값은 0.155, 0.151, 0.131, 0.130, 0.120, 0.111, 0.109, 0.108, 0.107, 0.106, 0.106, 0.103, 0.102, 0.102, 0.099, 0.093, 0.091, 0.089, 0.089, 0.087으로 계산 되었다.



(a) 스케일링 전



(b) 스케일링 후

Figure 5. 특성 스케일링 전과 후 그래프

상위 20 개의 특성 중 Figure 5 는 Sensor 103, 163, 210, 298 의 특성을 스케일링 전 (a)와 후 (b) 그래프로 비교 한 것인데, X 축은 특성 값 (Feature value)의 범위이고, Y 축은 특성 값의 범위를 일정한 간격으로 등분했을 때, 그 간격 내에 위치한 특성 값의 빈도 수(Frequency)이다. 스케일링 전후를 비교하면 특성들이 정규화된 것을 알 수 있다.

4.2 레이블 정보가 있는 경우 지도 학습

군집 수 $k=2$ 와 양품과 불량품 레이블 정보가 존재하므로 지도 학습 방법 중 Logistic Regression 방법을 적용하였다. Table 2~4 와 같이 특성은 590 개 중 4.1 절 데이터 전처리 과정에서 선택된 20 개를 적용하고 1567 개 데이터 중 80%인 1253 개의 Training 데이터로 양품과 불량품 군집간의 불균형에 대한 Sampling 을 적용하지 않은 경우 (Table 2 양품 1,160 개 불량품 93 개로 추가로 sampling 하지 않음), Over-sampling (Table 3 양품 1,178 개 불량품 75 개로 불량품의 수를 추가로 sampling 하여 군집 간 밸런스를 맞춤)을 적용한 경우, Under-sampling (Table 4 양품 1,169 개 불량품 84 개로 양품의 수를 줄여 군집 간 밸런스를 맞춤)을 적용한 경우에 데이터를 임의적으로 선택하여 모델링 하였다.

Table 5~7 은 Training 데이터 기반 모델로 예측한 해를 Testing 데이터 314 개로 평가하기 위해 2.1 절에서 설명한 정확도(accuracy), 정밀도(precision), 재현율 (recall), F1 score 를 적용하여 실험한 결과이다. Training 데이터 기반 모델로 예측한 해와 실제 해를 비교 평가하는 각 F1 score 의 best 는 0.1429, 0.3077 0.2281 로 Over-sampling 한 경우 0.3077 으로 가장 좋은 F1-score 를 제시할 수 있었다. Kang & et al. (2022)은 분류 알고리즘인 Support Vector Classifier (SVC), Multilayer Perceptron (MLP), Random Forest (RF), Gradient Boosted Trees (GBDT), GUSBoostedTree (RUSBT)를 SECOM 데이터에 적용하여 결과를 제시 하였다. 이들의 결과에 따르면, Sampling 을 적용하지 않은 데이터인 경우 RUSBT 의 F1 score 가 가장 높은 0.19, Over-sampling 을 적용한 데이터인 경우 RF 의 F1 score 가 가장 높은 0.24, RUSBT 0.19, GBDT 0.18, RF 0.29, GBDT 0.15 를 제시하였다. 본 연구에서 제안한 WFDPMML 이 예측한 해의 F1 score 가

0.3077 이므로 Kang & et al. (2022)이 제안한 방법들 예측 해의 F1 score 보다 상대적으로 우수함을 검증할 수 있었다.

Table 2. Sampling 을 적용하지 않은 데이터

SECOM 데이터			
샘플 수	1567	특성 수	590
Training 데이터			
샘플 수	1253	특성 수	20
불량품 수	93	불량율	7%
Testing 데이터			
샘플 수	314	특성 수	20
불량품 수	11	불량율	4%

Table 3. Over-sampling 을 적용한 데이터

SECOM 데이터			
샘플 수	1567	특성 수	590
Training 데이터			
샘플 수	1253	특성 수	20
불량품 수	75	불량율	6%
Testing 데이터			
샘플 수	314	특성 수	20
불량품 수	29	불량율	9%

Table 4. Under-sampling 을 적용한 데이터

SECOM 데이터			
샘플 수	1567	특성 수	590
Training 데이터			
샘플 수	1253	특성 수	20
불량품 수	84	불량율	7%
Testing 데이터			
샘플 수	314	특성 수	20
불량품 수	20	불량율	6%

Table 5. F1 score 결과 Sampling 없는 경우

실험	정확도	정밀도	재현율	F1 score
1	0.9236	0.3333	0.0435	0.0769
2	0.9427	0.0000	0.0000	0.0000
3	0.9127	0.0000	0.0000	0.0000
4	0.9395	0.0000	0.0000	0.0000
5	0.9618	0.3333	0.0909	0.1429

Table 6. F1 score 결과 Over-sampling 한 경우

실험	정확도	정밀도	재현율	F1 score
1	0.7134	0.1635	0.8500	0.2742
2	0.7229	0.1304	0.6316	0.2162
3	0.6943	0.1574	0.7727	0.2615
4	0.7166	0.1666	0.8095	0.2764
5	0.7134	0.1980	0.6897	0.3077

Table 7. F1 score 결과 Under-sampling 한 경우


실험	정확도	정밀도	재현율	F1 score
1	0.6911	0.1188	0.6000	0.1983
2	0.6815	0.1020	0.4545	0.1667
3	0.7134	0.1263	0.6316	0.2105
4	0.7197	0.1383	0.6500	0.2281
5	0.7134	0.0889	0.5000	0.1509

4.3 레이블 정보가 없는 경우 비지도 학습


정보가 존재하지 않을 경우는 적절한 군집 수 결정과 데이터 전처리를 통해 590 개 특성 중 선택된 422 개 특성을 모두 고려하여 분석하는 과정이 필요하지만, 본 실험에서는 웨이퍼 가공 1567 개 데이터와 20 개 특성만이 존재하고 군집 수는 $k=2$ 라는 가정하에 분석하였다.

Figure 6 (a)는 2.2 절에서 설명한 Intra-cluster distance 평가 기준 WFDPMML의 평균값 수렴 경향을 나타내는 그래프이다. WFDPMML은 효율적인 초기 해 생성 방법 (김성수 외 1인 특허 출원 등록 10-2142767)을 사용했기 때문에 초기해 군의 Intra-cluster distance 평균값은 약 5250으로 HMHA의 약 5270보다 더 좋은 초기 해들로 탐색을 시작할 수 있다. 수렴 과정을 통하여 WFDPMML의 최종 해군의 평가값 평균은 약 5000으로 HMHA (김성수 외 2인 특허 출원 10-2022-0088295)의 약 5107보다 우수하였다. 최종 세대 (약 300 세대) 해 군의 20 개 해 평가값의 best 값은 약 4805로 같으나 WFDPMML 방법이 HMHA보다 평균값이 우수하고 표준편차가 작아 안정적인 해 탐색이 가능한 것으로 분석되었다.

Figure 6 (b)는 2.3 절에서 설명한 Silhouette 평가 기준 WFDPMML의 평균값 수렴 경향을 나타내는 그래프이다. WFDPMML은 효율적인 초기 해 생성 방법을 사용했기 때문에 초기해 군의 Silhouette 평균값은 약 0.12으로 HMHA의 약 0.08보다 약간 우수한 초기해 군으로 탐색을 시작한다. 수렴 과정을 통하여 WFDPMML의 최종해 군의 평균은 약 0.73으로 HMHA와 유사하다. 최종 세대 (약 300 세대) 해 군의 20 개 해의 평가값의 best 값은 WFDPMML이 약 0.80으로 HMHA의 약 0.79보다 약간 우수하였다.



(a) intra-cluster distance 평가 기준 평균값



(b) Silhouette 평가 기준 평균값

Figure 6 WFDPMML 적용 평가값 수렴 경향

5. 결론

복잡한 반도체 공정 관리 시 불량을 유발하는 특성 데이터를 분석하고 조절해 불량 가능성을 최소화하고 안정적인 공정 과정을 유지할 수 있도록 함으로써 제조 수율과 수익성 향상이 필요하다. 즉, 반도체 공정 과정의 예방 유지보수 차원에서 불량을 사전에 방지하기 위해서는 공정 상의 문제와 원인을 데이터 분석을 통하여 사전에 파악하고 진단을 한 후 대책을 찾아 문제를 해결하는 것이다. 따라서 반도체 생산 장비의 센서에서 수집되는 데이터를 분석하여 실시간으로 웨이퍼의 양품과 불량품을 분류하고 문제점을 파악하고 해결책을 찾아 사전에 예방하는 것이 필요하다.

본 연구에서는 효율적인 반도체 공정 관리를 위한 데이터 전처리 및 기계학습(Wafer Fabrication Data Preprocessing & Machine Learning, WFDPMML) 방법을 제안하였다. WFDPMML은 기존 데이터의 레이블 정보가 존재 하는 지도 학습 또는 정보가 존재하지 않는 비지도 학습의 다양한 상황 하에서 적절한 해 예측 또는 탐색 및 평가가 가능하다. 제안한 WFDPMML을 레이블 정보가 존재 하는 SECOM 데이터의 분류 문제를 지도 학습 방법으로 실험 분석하였다. 또한, SECOM 데이터가 레이블 정보가 존재하지 않는 군집 문제로 가정하고 비지도 학습 방법의 성능을 검증하였다. 실험 결과에 따르면 기존 데이터의 정보 유무에 상관 없이 WFDPMML의 성능을 검증하고 데이터 전처리 및 기계학습 분석 결과를 제시할 수 있었다.

참고문헌

- [1] 김성수, 차영훈, 정석민, 기계학습 군집을 위한 조화로운 메타휴리스틱 알고리즘, 특허 출원 (번호 10-2022-0088295), 2022
- [2] 김성수, 강범수, 데이터간 상대적 거리 비율 및 클러스터의 중심 데이터 간의 거리를 고려한 데이터 클러스터링 방법 및 시스템, 특허등록 (번호 1021427670000), 2020
- [3] 김성수, 백준영, 강범수, 데이터 군집화를 위한 혼합 시뮬레이티드 어닐링, 한국산업경영시스템학회지 2017년 6월, Vol. 40 No. 2 p.92-98

- [4] ‘수율’, IT 용어사전, 네이버 지식백과
- [5] 서희원, 반도체 수율 개선의 1 등 공신이라는 '공정 제어' 기술은, 전자신문, 2021 년 6 월
- [4] Cho, E, *et al.*, Data Preprocessing Combination to Improve the Performance of Quality Classification in the Manufacturing Process, *Electronics* 2022, 11, 477. <https://doi.org/10.3390/electronics11030477>
- [5] Dogan, A., Birant, D. Machine Learning and Data Mining in Manufacturing. *Expert Syst. Appl.* 2021, 166, 114060.
- [6] Dong, M. (2019). Combining Unsupervised and Supervised Learning for Asset Class Failure Prediction in Power Systems. *IEEE Transactions on Power Systems*, 34(6), 5033–5043. doi:10.1109/TPWRS.2019.2920915.
- [7] Espadinha-Cruz. and *et al.*, A Review of Data Mining Applications in Semiconductor Manufacturing, *Processes* 2021, 9(2), 305; <https://doi.org/10.3390/pr9020305>
- [8] Hossin, M., & Sulaiman, M. N. (2015). A Review on Evaluation Metrics for Data Classification Evaluations. *International Journal of Data Mining & Knowledge Management Process*, 5, 01–11. <https://doi.org/10.5121/ijdkp.2015.5201>
- [9]Huang & *et al.*, An energy-efficient and trustworthy unsupervised anomaly detection framework (EATU) for IIoT, *ACM Transactions on Sensor Networks* Accepted on May 2022 <https://doi.org/10.1145/3543855>
- [10] Jang & Kim, Unstructured borderline self-organizing map: Learning highly imbalanced, high-dimensional datasets for fault detection, *Expert Systems With Applications* 188 (2022) 116028
- [11] Kang, Z. *et al.*, Product failure detection for production lines using a data-driven model, *Expert Systems with Applications* Volume 202, 15 September 2022, 117398
- [12] Krishna, K., and Murty, M. N., Genetic K-means algorithm, *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 1999, Vol. 29, No. 3, pp. 433-439.
- [13] SECOM Data Set, <https://archive.ics.uci.edu/ml/datasets/SECOM>
- [14] Data Analysis in Semiconductor Manufacturing, https://rstudio-pubs-static.s3.amazonaws.com/412485_a6031260e33e4b4b92cdeb1e18bf5375.html